8회차 자료집 · 29~32차시

k-NN을 다섯 단계로 손으로 풀어 보는 자료집

표준화 → 거리 → 정렬 → k개 고르기 → 다수결. 계산기 하나로 따라갈 수 있게 숫자를 모두 풀어 두었습니다.

과목 **인공지능 융합프로젝트** 단원 **III. 융합 프로젝트 구현** 함께 쓰는 자료 웹 실습실 · 코랩 노트북

이 자료집을 마치면 할 수 있는 것

① k-NN이 새 기록을 판정하는 다섯 단계를 **손으로 계산**할 수 있다. ② 표준화와 k가 결과를 어떻게 바꾸는지 **설명**할 수 있다. ③ 정확도와 혼동행렬로 모델을 **평가**하고, 어떤 실수가 더 위험한지 **판단**할 수 있다. ④ 모델이 찾은 최적 조건을 **제어 규칙**으로 옮길 수 있다.

1 k-NN 한눈에 보기

k-최근접 이웃(k-Nearest Neighbors)은 "**새 기록과 가장 닮은 기록 k개를 찾아, 그들이 가장 많이 가진 답을 따른다**"가 전부인 알고리즘입니다.

전학 온 친구의 취향을 짐작하는 방법을 떠올려 보세요. 새 친구와 **가장 비슷한 친구 다섯 명**을 찾아, 그중 셋이 축구를 좋아하면 새 친구도 축구를 좋아하리라 짐작합니다. k-NN은 이 방법을 숫자로 합니다. '비슷하다'를 **거리**로, '다섯 명'을 **k**로, '셋이 좋아하면'을 **다수결**로 바꾼 것입니다.

STEP 1	STEP 2	STEP 3	STEP 4	STEP 5
표준화	거리 계산	정렬	k개 고르기	다수결
단위를 맞춘다	모든 기록과	가까운 순서로	이웃 정하기	판정

특징	뜻	스마트 화분에서는
게으른 학습	미리 규칙을 만들지 않고 기록을 외워 두었다가, 물어볼 때마다 계산한다	기록이 늘어도 다시 학습할 필요가 없다. 대신 판정할 때마다 계산이 든다
거리 기반	'닮음'을 거리로 잰다	단위가 다른 센서(%, °C, lux)는 **반드시 표준화**해야 한다
설명이 쉽다	"이 기록들과 닮아서 이렇게 판정했다"고 이웃을 보여 줄 수 있다	"지난주 화요일과 비슷해서 위험"이라고 말할 수 있다
모든 변수를 똑같이 믿는다	관계없는 변수도 거리에 그대로 들어간다	식물과 무관한 **소음**을 넣으면 오히려 나빠진다

2 예제 데이터 — 몬스테라 화분 8개

손으로 계산할 수 있도록 변수 두 개(토양 수분, 조도)와 기록 8개만 씁니다. 몬스테라의 적정 범위는 **토양 수분 40~60%**, **조도 5,000~15,000 lux**입니다.

기록	토양 수분 (%)	조도 (lux)	상태
A	52	9,000	건강
B	47	9,500	건강
C	58	6,500	건강
D	30	9,800	위험
E	36	7,000	주의
F	55	2,500	주의
G	70	8,800	주의
H	31	8,200	위험
Q	**34**	**9,300**	**?**

새 화분 Q를 판정합니다

Q는 토양 수분이 34%로 적정 범위(40~60%)보다 **낮고**, 조도는 9,300 lux로 적정입니다. 사람이 보면 "물이 부족하다"고 판단할 만합니다.

그런데 표준화를 하지 않은 k-NN은 Q를 **건강**이라고 판정합니다. 왜 그런지 다섯 단계를 따라가며 확인해 봅시다.

3 STEP 1 · 표준화 — 단위를 맞춘다

토양 수분은 27~70 사이에서 움직이지만, 조도는 2,500~9,800 사이에서 움직입니다. 그대로 거리를 재면 **숫자가 큰 조도가 거리를 혼자 결정**합니다.

$$z = (x - \text{평균}) \div \text{표준편차}$$

표준화한 값 z는 "평균에서 표준편차 몇 개만큼 떨어져 있나"를 뜻합니다. 이제 두 변수 모두 같은 단위가 됩니다.

구하는 값	토양 수분	조도
평균 μ (8개 기록)	(52+47+58+30+36+55+70+31) ÷ 8 = **47.375**	61,300 ÷ 8 = **7,662.5**
분산 (편차²의 평균)	175.48	4,969,843.75
표준편차 σ (분산의 제곱근)	**13.25**	**2,229.3**

기록	z(수분) = (수분 − 47.375) ÷ 13.25	z(조도) = (조도 − 7,662.5) ÷ 2,229.3
A	0.35	0.60
B	−0.03	0.82
C	0.80	−0.52
D	−1.31	0.96
E	−0.86	−0.30
F	0.58	−2.32
G	1.71	0.51
H	−1.24	0.24
Q	**(34 − 47.375) ÷ 13.25 = −1.01**	**(9,300 − 7,662.5) ÷ 2,229.3 = 0.73**

흔한 실수 — 평균과 표준편차는 훈련 기록으로만

새 화분 Q의 값으로 평균을 다시 계산하면 안 됩니다. 실제 수업 코드에서도 `scaler.fit_transform(X_train)` 으로 훈련 데이터의 평균·표준편차를 구하고, 시험 데이터에는 `scaler.transform(X_test)` 로 **같은 값을 그대로** 씁니다. 시험지를 미리 보고 공부하지 않는 것과 같은 원칙입니다.

※ 이 자료집과 scikit-learn은 표준편차를 구할 때 n으로 나눕니다(모표준편차).

4 STEP 2 · 거리 계산 — 모든 기록과

새 화분 Q와 기록 8개 **모두** 사이의 거리를 잽니다. 가장 많이 쓰는 것은 **유클리드 거리**(직선 거리)입니다.

$$d = \sqrt{\left(\left(\Delta z_{수분}\right)^2 + \left(\Delta z_{조도}\right)^2\right)}$$

계산 예 — Q와 D 사이

$\Delta z_{수분} = -1.31 - (-1.01) = -0.30$, $\Delta z_{조도} = 0.96 - 0.73 = 0.22$

$d = \sqrt{(0.30^2 + 0.22^2)} = \sqrt{(0.090 + 0.048)} = \sqrt{0.138} \approx$ **0.37** (소수 둘째 자리에서 반올림한 z로 계산해 컴퓨터 값 0.38과 조금 다를 수 있습니다)

기록	Δz 수분	Δz 조도	유클리드 거리 (표준화 O)	맨해튼 거리 (표준화 O)	유클리드 거리 (표준화 X)	상태
A	1.36	−0.13	1.37	1.49	300.5	건강
B	0.98	0.09	0.99	1.07	200.4	건강
C	1.81	−1.26	2.20	3.07	2,800.1	건강
D	−0.30	0.22	0.38	0.53	500.0	위험
E	0.15	−1.03	1.04	1.18	2,300.0	주의
F	1.59	−3.05	3.44	4.64	6,800.0	주의
G	2.72	−0.22	2.73	2.94	501.3	주의
H	−0.23	−0.49	0.54	0.72	1,100.0	위험

맨해튼 거리

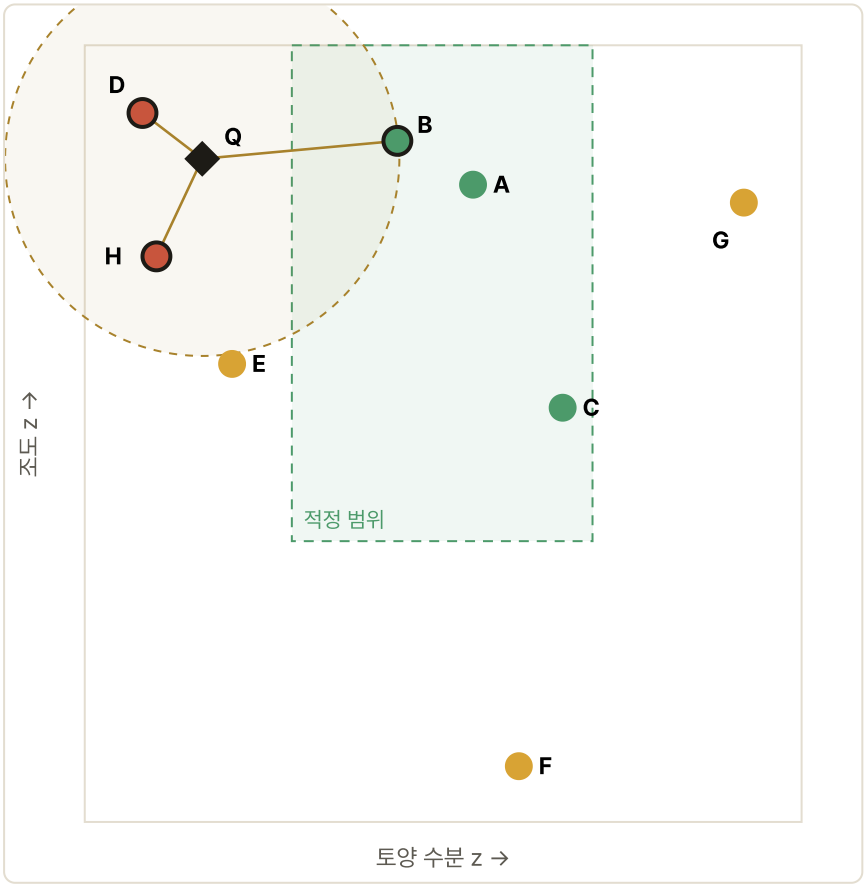
가로·세로로만 걷는 거리입니다. $d = |\Delta z_{수분}| + |\Delta z_{조도}|$. 이 예제에서는 순위가 거의 같지만, 변수가 많아지면 결과가 달라지기도 합니다.

표준화를 하지 않으면

맨 오른쪽 열을 보세요. B까지 200.4인데 이 중 수분 차이(13)는 거의 기여하지 않습니다. $\sqrt{(13^2 + 200^2)} \approx \sqrt{(200^2)}$이기 때문입니다. **토양 수분은 사실상 무시되고 조도만으로 이웃이 정해집니다.**

5 STEP 3 · 정렬 — 가까운 순서로

순위	표준화 O (유클리드)			표준화 X (유클리드)		
	기록	거리	상태	기록	거리	상태
1	**D**	**0.38**	위험	**B**	**200.4**	건강
2	**H**	**0.54**	위험	**A**	**300.5**	건강
3	**B**	**0.99**	건강	**D**	**500.0**	위험
4	E	1.04	주의	G	501.3	주의
5	A	1.37	건강	H	1,100.0	위험
6	C	2.20	건강	E	2,300.0	주의
7	G	2.73	주의	C	2,800.1	건강
8	F	3.44	주의	F	6,800.0	주의



표준화한 공간. Q(◆)를 중심으로 세 번째 이웃 B까지의 원 안에 D·H·B가 들어갑니다. 초록 점선은 몬스테라의 적정 범위입니다.

6 STEP 4 · k개 고르기

위에서부터 k개를 이웃으로 고릅니다. **k를 무엇으로 하느냐**에 따라 판정이 달라집니다.

k	표준화 O · 이웃	투표 (건강·주의·위험)	판정	표준화 X · 판정
1	D	0 · 0 · 1	위험	건강
3	**D, H, B**	**1 · 0 · 2**	위험	건강 (B·A 건강, D 위험)
5	D, H, B, E, A	2 · 1 · 2	동점 → 가장 가까운 D를 따라 위험	동점 → B를 따라 건강
7	D, H, B, E, A, C, G	3 · 2 · 2	건강	건강

k가 너무 작으면 — 과대적합

k = 1은 가장 가까운 기록 하나만 믿습니다. 그 기록이 잡음(측정 오류, 이상한 식물)이면 판정이 그대로 틀립니다. 훈련 데이터로 시험하면 자기 자신이 이웃이 되어 정확도가 **1.0**이 나오지만, 새 화분에서는 흔들립니다.

k가 너무 크면 — 과소적합

k = 7이면 8개 중 7개가 투표합니다. 멀리 있는 C·G까지 끼어들어, 결국 **기록이 많은 상태**로 쏠립니다. k = 8이면 무엇을 물어도 같은 답이 나옵니다.

k 고르는 원칙

① **홀수**에서 출발합니다(두 상태라면 동점이 사라지고, 세 상태여도 동점이 줄어듭니다). ② 동점이면 **더 가까운 이웃의 상태**를 따르게 정해 둡니다. ③ 최종 k는 **훈련 데이터 안에서 교차검증**으로 고릅니다. 시험 데이터를 보며 k를 고르면 시험 문제를 미리 본 것과 같습니다.

7 STEP 5 · 다수결 — 판정과 확률

k = 3, 표준화한 경우 이웃은 D(위험), H(위험), B(건강)입니다. 투표 결과 **위험 2 : 건강 1** → Q는 위험입니다. 사람의 판단("물이 부족하다")과 일치합니다.

투표 비율 = 확률

위험 2/3 ≈ 0.67, 건강 1/3 ≈ 0.33, 주의 0. scikit-learn의 `predict_proba()`가 돌려주는 값이 바로 이것입니다. 확률이 0.4 · 0.2 · 0.4처럼 갈리면 판정을 그대로 믿기 어렵다는 신호입니다.

더 나아가기 — 거리 가중 투표

가까운 이웃의 표를 더 무겁게 셀 수도 있습니다(가중치 = 1 ÷ 거리). D 1/0.38 = 2.63, H 1/0.54 = 1.85, B 1/0.99 = 1.01 → 위험 4.48 : 건강 1.01.

`KNeighborsClassifier(weights="distance")`로 쓸 수 있습니다.

8 코드로 옮기기

numpy로 직접 — 다섯 단계가 다섯 줄

```
# X_train: (기록 수 × 변수 수) 배열, y_train: 상태(0 건강 · 1 주의 · 2 위험), x_new: 새 화분
mu, sd = X_train.mean(axis=0), X_train.std(axis=0)
Z_train, z_new = (X_train - mu) / sd, (x_new - mu) / sd                # STEP 1 표준화
d = np.sqrt(((Z_train - z_new) ** 2).sum(axis=1))                      # STEP 2 거리
nb = np.argsort(d)[:k]                                                 # STEP 3 정렬 + STEP 4 k
pred = np.bincount(y_train[nb], minlength=3).argmax()                  # STEP 5 다수결
```

scikit-learn으로 — 표준화와 k-NN을 한 줄로 묶기

```
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier

model = make_pipeline(StandardScaler(), KNeighborsClassifier(n_neighbors=5))
model.fit(X_train, y_train)            # 평균·표준편차는 훈련 데이터로만 계산된다
model.predict(X_test)                  # 시험 데이터는 같은 기준으로 변환된 뒤 판정
model.predict_proba(X_test)            # 투표 비율(확률)
```

> 코랩 노트북 3장에서 두 방법의 예측이 **100% 같다**는 것을 직접 확인합니다. 파이프라인으로 묶으면 '시험 데이터로 평균을 다시 구하는' 실수를 원천적으로 막을 수 있습니다.

설계에 따라 달라지는 성능 — 실습 데이터(몬스테라 240개) 결과

설계	평균 정확도 (10번 반복)	읽기
A · 4개 변수, 표준화 **X**	0.53	조도(lux)가 거리를 독차지
B · 4개 변수, 표준화 O	0.71	표준화 하나로 크게 오른다
C · B + 조도 로그 변환	0.72	이 데이터에서는 차이가 작다
D · C + **소음**(관계없는 변수)	0.61	쓸데없는 변수가 이웃을 엉뚱하게 고른다
E · 토양 수분 하나만	0.51	한 변수로는 부족하다

9 정확도와 혼동행렬

몬스테라 기록 240개를 훈련 192개 · 시험 48개로 나누고 k = 5로 학습한 결과입니다(코랩 노트북 5장과 같은 조건).

실제 ↓ / 예측 →	예측			합계
	건강	주의	위험	
건강	**18**	0	0	18
주의	7	**3**	0	10
위험	**3**	1	**16**	20
합계	28	4	16	48

정확도 = 대각선 합 ÷ 전체 = (18+3+16) ÷ 48 = **0.771**

모든 화분을 가장 많은 상태(위험, 20개)로 찍기만 해도 20 ÷ 48 = **0.417**입니다. 이 **기준선**보다 얼마나 나은지가 진짜 실력입니다.

상태	재현율 = 맞힌 수 ÷ 실제 수	정밀도 = 맞힌 수 ÷ 그렇게 예측한 수	읽기
건강	18 ÷ 18 = **1.00**	18 ÷ 28 = **0.64**	건강은 다 잡았지만, '건강'이라는 판정의 1/3은 틀렸다
주의	3 ÷ 10 = **0.30**	3 ÷ 4 = **0.75**	주의를 대부분 건강으로 넘겼다 — 경계에 있는 상태라 헷갈린다
위험	16 ÷ 20 = **0.80**	16 ÷ 16 = **1.00**	위험이라고 하면 확실하지만, 위험 5개 중 1개는 놓쳤다

가장 무거운 칸 — 실제 위험 → 건강으로 예측 (3건)

자동 급수기는 이 화분을 '괜찮다'며 그냥 둡니다. 식물은 시듭니다. 반대로 '실제 건강 → 위험'(0건)은 괜히 한 번 더 살펴보는 실수입니다. **틀린 칸마다 대가가 다르므로**, 정확도가 같아도 이 칸이 작은 모델을 고릅니다. 어느 실수를 줄일지는 **사람이 정하는 문제**입니다.

10 최적 조건에서 제어 규칙까지

모델에게 최적 조건을 묻는 방법

다른 변수는 적정 범위 가운데에 두고 **한 변수만** 조금씩 바꾸며, k-NN이 '건강'이라고 투표하는 비율(건강 확률)을 계산합니다. 확률이 70% 이상인 구간이 **데이터가 알려 준 최적 범위**입니다.

몬스테라 (k = 15)	문헌 적정 범위	모델이 찾은 범위 (건강 확률 ≥ 70%)
토양 수분	40 ~ 60 %	34 ~ 65 %
온도	18 ~ 27 °C	17 ~ 29 °C
조도	5,000 ~ 15,000 lux	약 3,600 ~ 21,000 lux
습도	50 ~ 70 %	46 ~ 75 %

모델의 범위가 조금 더 넓습니다. 이웃을 15개나 보기 때문에 경계가 부드럽게 번지고, 기록이 드문 가장자리에서는 먼 이웃까지 끌어오기 때문입니다. **데이터가 말해 준 값과 사람이 아는 값 중 무엇을 기준으로 삼을지**도 설계자가 판단합니다.

범위를 스위치로 — 히스테리시스

기준이 하나(예: 40%)뿐이면 수분이 39.9 ↔ 40.1을 오갈 때마다 펌프가 켜졌다 꺼집니다. 그래서 **켜는 값과 끄는 값을 다르게** 둡니다. **40% 아래로 내려가면 급수 시작, 56%에 닿으면 급수 끝.** 냉난방기의 온도 조절과 같은 원리입니다.

① 대기
수분 ≥ 시작 기준

② 급수 중
수분 < 시작 기준이 되면 진입

③ 3초 급수
펌프는 한 번에 3초만

④ 30분 스며들기
흙에 물이 퍼질 때까지 기다린 뒤 다시 잰다

⑤ 끝
수분 ≥ 멈춤 기준 → ①로

교과서 규칙(126쪽)을 다시 보면
교과서 코드는 "45% 미만이면 3초 급수 → 70%가 될 때까지 재급수 금지"입니다. 펌프 3초로 70%에 **닿지 못하면** 잠금이 풀리지 않아 다시는 물을 주지 않습니다. 웹 실습실 ⑥에서 확인해 보세요. 위의 ②~⑤처럼 '닿을 때까지 나눠서 준다'로 바꾸면 해결됩니다.

안전장치 네 가지

장치	막는 사고	코드에서는
히스테리시스	펌프·팬이 경계에서 수없이 켜졌다 꺼짐 (릴레이 마모)	시작 기준 ≠ 멈춤 기준
하루 급수량 상한	센서가 계속 '마름'을 읽어 물통을 다 쏟음	`water_today + ML_PER_RUN <= DAILY_CAP_ML`
센서 이상 감지	선이 빠져 0%가 읽혀 물을 퍼부음	값이 범위를 벗어나거나 갑자기 25% 넘게 튀면 무시
이동평균 필터	한 번 튄 잡음 때문에 잘못 작동	최근 3회 값의 평균으로 판단

11 마이크로비트 안의 k-NN

k-NN은 '기록을 외워 두는' 알고리즘이라, 기록을 코드에 그대로 넣으면 마이크로비트 안에서도 돌아갑니다. 내장 센서로 잴 수 있는 **토양 수분 · 온도 · 조도** 세 변수와, 상태별 30개씩 **90개 기록**을 넣습니다.

거래 — 정확도 vs 메모리

컴퓨터에서 4개 변수 · 192개 기록으로 만든 모델은 약 **0.72~0.77**, 마이크로비트용 3개 변수 · 90개 모델은 약 **0.63**입니다. 습도 센서가 없고 기록도 적기 때문입니다. 대신 인터넷 없이, 2초마다, 배터리로 판정합니다.

판정은 AI가, 행동은 규칙이

k-NN이 '주의·위험'이라고 해도 바로 물을 주지는 않습니다. **원인이 수분일 때만** 급수합니다. 어두워서 '주의'인 화분에 물을 주면 과습이 되기 때문입니다. 웹 실습실 ⑥의 코드 생성기에서 [k-NN 판단]을 고르면 전체 코드를 받을 수 있습니다.

12 손계산 활동지

2장의 기록 8개는 그대로 두고, 새 화분 **Q2 = (토양 수분 56%, 조도 4,200 lux)**를 판정하세요. 평균과 표준편차는 3장의 값을 씁니다.

단계	할 일	답
1	Q2의 z(수분) = (56 − 47.375) ÷ 13.25	_____
1	Q2의 z(조도) = (4,200 − 7,662.5) ÷ 2,229.3	_____

기록	z 수분	z 조도	Δz 수분	Δz 조도	거리 d	순위	상태
A	0.35	0.60					건강
B	−0.03	0.82					건강
C	0.80	−0.52					건강
D	−1.31	0.96					위험
E	−0.86	−0.30					주의
F	0.58	−2.32					주의
G	1.71	0.51					주의
H	−1.24	0.24					위험

k = 3일 때 이웃 세 개	_____ , _____ , _____
투표 결과 (건강 · 주의 · 위험)	_____ · _____ · _____
Q2의 판정과 '주의' 확률	_____ , _____
표준화하지 않고 계산하면 판정이 달라지나요? (거리 = √(Δ수분² + Δ조도²))	_____
Q2는 몬스테라의 적정 범위 중 무엇이 어긋났나요? 판정과 맞나요?	_____

13 확인 문제

1 k-NN에 표준화가 꼭 필요한 이유로 가장 알맞은 것은?

1. 학습 속도를 높이려고
2. 거리를 재므로 값의 범위가 큰 변수가 결과를 지배하기 때문에
3. 정확도를 1.0으로 만들려고
4. 변수 개수를 줄이려고

2 표준화에 쓰는 평균과 표준편차는 어떤 데이터로 구해야 하나요? 이유와 함께 쓰세요.

3 k = 1일 때 훈련 데이터에 대한 정확도는 항상 1.0입니다(같은 값의 기록이 없을 때). 그 이유는?

4 2장 예제에서 k = 7이면 Q의 판정이 '건강'으로 바뀝니다. 왜 그런지 '과소적합'이라는 말을 넣어 설명하세요.

5 9장의 혼동행렬에서 '주의'의 재현율과 정밀도를 각각 구하세요.

6 정확도가 0.77로 같은 두 모델이 있습니다. 모델 甲은 '실제 위험 → 건강'이 3건, 모델 乙은 0건입니다. 스마트 화분에는 어느 모델을 쓰겠습니까? 이유는?

7 식물과 관계없는 '소음'을 변수에 넣었더니 k-NN의 정확도가 떨어졌습니다. 이유를 '거리'라는 말을 넣어 설명하세요.

8 급수 시작 기준을 40%, 멈춤 기준을 56%로 다르게 둔 이유는? 같은 값으로 두면 어떤 일이 생길까요?

14 정답과 해설 · 용어

손계산 활동지 (12장)

z(수분) = 8.625 ÷ 13.25 ≈ **0.65**, z(조도) = −3,462.5 ÷ 2,229.3 ≈ **−1.55**

기록	Δz 수분	Δz 조도	거리 d	순위
A	−0.30	2.15	2.17	4
B	−0.68	2.38	2.47	6
C	**0.15**	**1.03**	**1.04**	**2**
D	−1.96	2.51	3.19	8
E	**−1.51**	**1.26**	**1.96**	**3**
F	**−0.08**	**−0.76**	**0.77**	**1**
G	1.06	2.06	2.32	5
H	−1.89	1.79	2.60	7

이웃: **F(주의), C(건강), E(주의)** → 투표 건강 1 · 주의 2 · 위험 0 → 판정 **주의**, 주의 확률 2/3 ≈ 0.67. 표준화하지 않아도 이웃은 F(1,700), C(2,300), E(2,800)로 같아 판정이 같습니다 — **이번에는 운이 좋았을 뿐**입니다. Q2는 수분은 적정이지만 **조도 4,200 lux가 하한 5,000보다 낮습니다.** '어두워서 주의'이므로 물이 아니라 **식물등**이 필요합니다.

확인 문제 (13장)

1 ② · 범위가 큰 조도(수천 lux)가 거리를 독차지하면 다른 변수는 무시됩니다.

2 훈련 데이터로만. 시험 데이터의 정보가 학습에 섞이면(누설) 실제보다 성적이 좋게 나옵니다. 시험 데이터에는 훈련 데이터의 평균·표준편차를 그대로 씁니다.

3 훈련 기록 자신이 거리 0으로 가장 가까운 이웃이 되어, 자기 상태를 그대로 맞히기 때문입니다. 새 데이터에서는 이만큼 잘하지 못합니다(과대적합).

4 8개 중 7개가 투표하면 멀리 있는 C·G까지 참여해, 가까운 이웃의 정보가 묻히고 기록이 많은 쪽(건강 3개)으로 쏠립니다. 데이터의 패턴을 충분히 반영하지 못하는 과소적합입니다.

5 재현율 3 ÷ 10 = 0.30, 정밀도 3 ÷ 4 = 0.75.

6 모델 乙. 실제 위험을 건강으로 놓치면 자동 급수기가 아무것도 하지 않아 식물이 시듭니다. 정확도가 같다면 더 위험한 실수가 적은 모델을 고릅니다.

7 k-NN은 모든 변수를 똑같이 거리 계산에 넣습니다. 관계없는 소음 차이가 거리를 키우거나 줄여서, 실제로는 닮지 않은 기록이 이웃으로 뽑힙니다.

8 기준이 하나면 수분이 그 값 근처를 오갈 때마다 펌프가 켜졌다 꺼지기를 반복합니다(릴레이 마모, 소음, 과습). 켜는 값과 끄는 값을 벌려 두면 한 번 켜지면 충분히 준 뒤 꺼집니다 — 히스테리시스.

용어

k-NN	가장 가까운 기록 k개의 다수결로 판정하는 지도학습 알고리즘
표준화	(값 − 평균) ÷ 표준편차. 단위가 다른 변수를 같은 눈금으로 맞추는 일
유클리드 · 맨해튼 거리	직선 거리 · 가로세로로만 걷는 거리
과대적합 · 과소적합	훈련 데이터에 지나치게 맞춤(k 너무 작음) · 패턴을 충분히 못 잡음(k 너무 큼)
교차검증	훈련 데이터를 여러 조각으로 나눠 돌아가며 시험해 k 같은 설정을 고르는 방법
정확도	전체 중 맞힌 비율. 상태별 개수가 고르지 않으면 속기 쉽다
혼동행렬	행 = 실제, 열 = 예측으로 맞힌 것과 틀린 것을 칸별로 센 표
재현율 · 정밀도	실제 그 상태 중 맞힌 비율 · 그 상태라고 한 것 중 맞은 비율
히스테리시스	켜는 기준과 끄는 기준을 다르게 두어 경계에서의 반복 작동을 막는 설계
데이터 누설	시험 데이터나 정답의 정보가 학습에 섞여 들어가 성적이 부풀려지는 현상

2026-2 온라인 공동교육과정 · 인공지능 융합프로젝트 — 대전대신고등학교 하진수 · 8회차 자료집. 예제와 실습 데이터는 교육용 가상 데이터이며, 식물 적정 범위는 여러 원예 자료를 종합한 출발점입니다. 8회차 수업 페이지 · 웹 실습실